АНАЛИТИЧЕСКИЙ ОТЧЁТ

Выявление мошеннических транзакций

Автор	Дербенцев Дмитрий Евгеньевич
Датасет	Financial Transactions Dataset (~13M строк)
Инструменты	SQL (SQLite), Python (Pandas, Matplotlib, Seaborn)
Цель	Выявление аномалий и мошеннических паттернов
Дата	2025 год

1. О проекте

Данный отчёт представляет результаты самостоятельного анализа датасета финансовых транзакций. Цель проекта — выявить подозрительные паттерны поведения клиентов и разработать систему скоринга рисков.

1.1 Описание данных

Таблица	Строк	Описание
transactions_data	13,305,915	Транзакции клиентов

2. SQL Анализ — Выявление аномалий

На первом этапе был проведён анализ данных с помощью SQL запросов в SQLite. Разработаны 4 гипотезы для выявления мошеннического поведения.

2.1 Velocity Check — Аномальная частота транзакций

Гипотеза: клиент с более чем 5 транзакциями за один день в разных локациях является подозрительным.

```sql
with custAVG as (
 SELECT client_id ,
 AVG(CAST(REPLACE(amount, '$', '') AS REAL)) as AVGTRANS
 from transactions_data
 where merchant_state is not null
 and merchant_city <> 'ONLINE'
 GROUP by client_id
),
CTE as (
 select client_id , count(*) as TRANSACTIONDAY,
  count(DISTINCT merchant_state) as uniq_trans ,
  AVG(CAST(replace(amount, '$', '') AS REAL)) as avgperday
 from transactions_data
 where merchant_state is not null
 and merchant_city <> 'ONLINE'
 group by client_id, date(date)

)

 select DISTINCT client_id, TRANSACTIONDAY, uniq_trans, round(avgperday / avgtrans , 2 ) as ratio_risk,
case
 when TRANSACTIONDAY > 10 THEN 'Критический'
when TRANSACTIONDAY > 5 Then 'Высокий'
 ELSE 'Средний'
end as Risk
 from CTE
 join custAVG using(client_id)
 where uniq_trans > 1
 and
 AVGTRANS * 2 < avgperday
 and
 TRANSACTIONDAY > 5
```

	client_id	TRANSACTIONDAY	uniq_trans	ratio_risk	Risk
1	0	6	2	3.48	Высокий
2	0	8	2	3.26	Высокий
3	0	7	2	2.44	Высокий
4	0	6	2	2.06	Высокий
5	0	7	3	3.43	Высокий
6	0	6	2	2.85	Высокий
7	0	7	2	2.01	Высокий
8	0	7	2	2.73	Высокий
9	0	10	3	2.31	Высокий
10	0	6	3	3.84	Высокий

Выводы:

- Найдены клиенты с аномально высоким числом транзакций за день
- Средний чек у таких клиентов превышает норму в 2+ раза
- Большинство аномальных транзакций — в нескольких штатах одновременно

2.2 Анализ мерчантов с ошибками

Гипотеза: мерчанты где более 20% транзакций содержат ошибки — потенциальные точки компрометации карт.

```sql
with mercherror as (
select merchant_id, SUM(CASE WHEN errors IS NOT NULL THEN 1 ELSE 0 END) , count(*) as total ,
round(SUM(CASE WHEN errors IS NOT NULL THEN 1 ELSE 0 END) / count(*) * 100 , 2 ) as totalerror,
round(avg(CAST(REPLACE(amount, '$', '') AS REAL)), 2 ) as avg_merchant
from transactions_data
GROUP by merchant_id
HAVING totalerror > 20
),

avgover1 as (
select round(avg(CAST(REPLACE(amount, '$', '') AS REAL)), 2 )as AVGover
from transactions_data
)
select merchant_id, merchant_state, avg_merchant, totalerror, AVGover, ROUND(avg_merchant - AVGover, 2) AS diff_from_avg
from transactions_data, avgover1
join mercherror using(merchant_id)
where totalerror > 20
ORDER BY avg_merchant DESC
```

	merchant_id	merchant_state	avg_merchant	totalerror	AVGover	diff_from_avg
1	11778	NY	338.76	100.0	42.97	295.79
2	24107	MT	320.92	100.0	42.97	277.95
3	73762	NC	303.86	100.0	42.97	260.89
4	4438	MA	267.27	100.0	42.97	224.3
5	93782	GA	263.85	100.0	42.97	220.88
6	87719	CA	239.47	100.0	42.97	196.5
7	55955	NE	234.68	100.0	42.97	191.71
8	67599	OR	225.7	100.0	42.97	182.73
9	30844	CA	217.94	100.0	42.97	174.97
10	2469	SD	217.84	100.0	42.97	174.87

Выводы:

- Мерчант 87719 (CA): средний чек $239.47 — на $196.5 выше среднего
- 100% транзакций у выявленных мерчантов содержат ошибки

2.3 Ночные аномалии

Гипотеза: клиенты у которых ночные транзакции (00:00-05:00) превышают дневные в 1.5+ раза — группа риска.

```sql
with night as (
SELECT  client_id , round(AVG(CAST(REPLACE(amount, '$', '') AS REAL)), 2) as avgn
from transactions_data
where strftime('%H', date) BETWEEN '00' and '05'
group by client_id
),

days as (
SELECT client_id, round(AVG(CAST(REPLACE(amount, '$', '') AS REAL)), 2) as avgd
from transactions_data
where strftime('%H', date) BETWEEN '06' and '23'
group by client_id
)

SELECT client_id, avgn , avgd, round(avgn / avgd ,2 ) as ratio ,
case
WHEN round(avgn / avgd ,2 ) > 4 then 'Критичность'
when round(avgn / avgd ,2 ) > 2 then 'Опасность'
else 'Внимание'
end as risk
from night
join days using(client_id)
where avgn / avgd > 1.5
ORDER BY ratio DESC
```

	client_id	avgn	avgd	ratio	risk
1	1494	350.67	25.61	13.69	Критичность
2	145	211.39	21.06	10.04	Критичность
3	59	203.39	25.33	8.03	Критичность
4	286	180.58	25.18	7.17	Критичность
5	1204	412.78	58.67	7.04	Критичность
6	524	196.71	30.34	6.48	Критичность
7	989	378.7	61.77	6.13	Критичность
8	63	95.01	15.56	6.11	Критичность
9	421	87.19	15.36	5.68	Критичность
10	199	218.05	39.14	5.57	Критичность

2.4 Быстрые транзакции

Гипотеза: две и более транзакции с интервалом менее 5 минут выше среднего чека — признак автоматизированного мошенничества.

SQL 1*

```sql
with dates as (
select client_id, date , lead(date) over(PARTITION by client_id order by date) as datee,
 amount ,
lead(amount) over(PARTITION by client_id order by date) as amoount
from transactions_data
),

over1 as (
select client_id , date , datee,  CEILING((julianday(datee) - julianday(date)) * 24 *60) AS diff_seconds, amount,  amoount
from dates
where CEILING((julianday(datee) - julianday(date)) * 24 *60 ) < 5  and CEILING((julianday(datee) - julianday(date)) * 24 * 60) <> 0
),

AVGover1 as  (
select round(AVG(CAST(REPLACE(amount, '$', '') AS REAL)), 2) as avgover
FROM transactions_data
)

select client_id, date, amount, avgover, diff_seconds, amoount , datee
from over1, AVGover1
where diff_seconds < 5 and diff_seconds <> 0 and CAST(REPLACE(amount, '$', '') AS REAL) > avgover and amoount > avgover and amoount not like '%-%'
```

	client_id	date	amount	avgover	diff_seconds	amoount	datee
1	0	2010-02-09...	$84.67	42.97	4.0	$53.00	2010-02-09 12:25:00
2	0	2010-02-09...	$53.00	42.97	3.0	$52.29	2010-02-09 12:28:00
3	0	2010-03-15...	$259.00	42.97	3.0	$13.01	2010-03-15 19:25:00
4	0	2010-03-23...	$63.67	42.97	4.0	$64.00	2010-03-23 12:48:00
5	0	2010-04-10...	$66.61	42.97	1.0	$86.00	2010-04-10 12:38:00
6	0	2010-04-15...	$69.00	42.97	1.0	$82.07	2010-04-15 12:55:00
7	0	2010-05-21...	$55.00	42.97	1.0	$69.95	2010-05-21 12:46:00
8	0	2010-07-14...	$69.00	42.97	1.0	$41.11	2010-07-14 12:57:00
9	0	2010-07-16...	$127.64	42.97	4.0	$465.21	2010-07-16 02:26:00
10	0	2010-07-21...	$107.25	42.97	4.0	$183.18	2010-07-21 16:24:00

2.5 Итоговый риск-скоринг

На основе четырёх гипотез построен скоринг: каждый сработавший флаг даёт +1 балл. Клиенты с 3-4 баллами — критический риск.

```sql
SELECT
    t.client_id,
    MAX(CASE WHEN t1.client_id IS NOT NULL THEN 1 ELSE 0 END) AS flag_velocity,
    MAX(CASE WHEN t2.client_id IS NOT NULL THEN 1 ELSE 0 END) AS flag_merch,
    MAX(CASE WHEN t3.client_id IS NOT NULL THEN 1 ELSE 0 END) AS flag_night,
    MAX(CASE WHEN t4.client_id IS NOT NULL THEN 1 ELSE 0 END) AS flag_fast_tx,

    -- Итоговый скор
    (MAX(CASE WHEN t1.client_id IS NOT NULL THEN 1 ELSE 0 END) +
     MAX(CASE WHEN t2.client_id IS NOT NULL THEN 1 ELSE 0 END) +
     MAX(CASE WHEN t3.client_id IS NOT NULL THEN 1 ELSE 0 END) +
     MAX(CASE WHEN t4.client_id IS NOT NULL THEN 1 ELSE 0 END)) AS risk_score,

    CASE
        WHEN (MAX(CASE WHEN t1.client_id IS NOT NULL THEN 1 ELSE 0 END) +
              MAX(CASE WHEN t2.client_id IS NOT NULL THEN 1 ELSE 0 END) +
              MAX(CASE WHEN t3.client_id IS NOT NULL THEN 1 ELSE 0 END) +
              MAX(CASE WHEN t4.client_id IS NOT NULL THEN 1 ELSE 0 END)) >= 3 THEN 'Критический'
        WHEN (MAX(CASE WHEN t1.client_id IS NOT NULL THEN 1 ELSE 0 END) +
              MAX(CASE WHEN t2.client_id IS NOT NULL THEN 1 ELSE 0 END) +
              MAX(CASE WHEN t3.client_id IS NOT NULL THEN 1 ELSE 0 END) +
              MAX(CASE WHEN t4.client_id IS NOT NULL THEN 1 ELSE 0 END)) = 2 THEN 'Высокий'
        ELSE 'Средний'
    END AS risk_level

FROM (SELECT DISTINCT client_id FROM transactions_data) t
LEFT JOIN task01 t1 ON t.client_id = t1.client_id
LEFT JOIN task02 t2 ON t.client_id = t2.client_id
LEFT JOIN task3 t3 ON t.client_id = t3.client_id
LEFT JOIN task4 t4 ON t.client_id = t4.client_id
GROUP BY t.client_id

HAVING (MAX(CASE WHEN t1.client_id IS NOT NULL THEN 1 ELSE 0 END) +
        MAX(CASE WHEN t2.client_id IS NOT NULL THEN 1 ELSE 0 END) +
        MAX(CASE WHEN t3.client_id IS NOT NULL THEN 1 ELSE 0 END) +
        MAX(CASE WHEN t4.client_id IS NOT NULL THEN 1 ELSE 0 END)) > 0

ORDER BY 6 DESC
```

	client_id	flag_velocity	flag_merch	flag_night	flag_fast_tx	risk_score	risk_level
1	1811	0	1	1	1	3	Критический
2	1769	1	1	0	1	3	Критический
3	1648	1	0	1	1	3	Критический
4	1452	1	0	1	1	3	Критический
5	1102	1	1	0	1	3	Критический

3. Python анализ — Визуализация и ML

На втором этапе я загрузил данные в Python и сделал несколько блоков работы: визуализацию, построение флагов, обучение ML моделей и итоговый риск-скоринг. Ниже — описание каждого графика и что он показывает.

3.1 Распределение уровней риска (Donut диаграмма)

Первое что я построил — круговая диаграмма с разбивкой клиентов по уровням риска. Каждый клиент получает уровень на основе суммы сработавших флагов: 0 флагов = Низкий, 1-2 = Средний, 3-4 = Высокий, 5+ = Критический.

Что показывает график:

- Низкий риск — большинство клиентов (~38%), поведение в норме
- Средний риск — 42.5%, есть один или два подозрительных паттерна
- Высокий риск — 19.1%, три и более флага сработало одновременно
- Критический — 0.4%, все четыре флага активны у одного клиента

Вывод: 62% клиентов имеют хотя бы один флаг. Это не значит что все они мошенники — часть может быть ложными срабатываниями, поэтому дальше добавляется ML для дополнительной фильтрации.

3.2 Активность по часам суток

График сравнивает долю транзакций по каждому часу между фрод-клиентами (risk_score >= 2) и нормальными клиентами. Позволяет визуально подтвердить гипотезу про ночные аномалии.

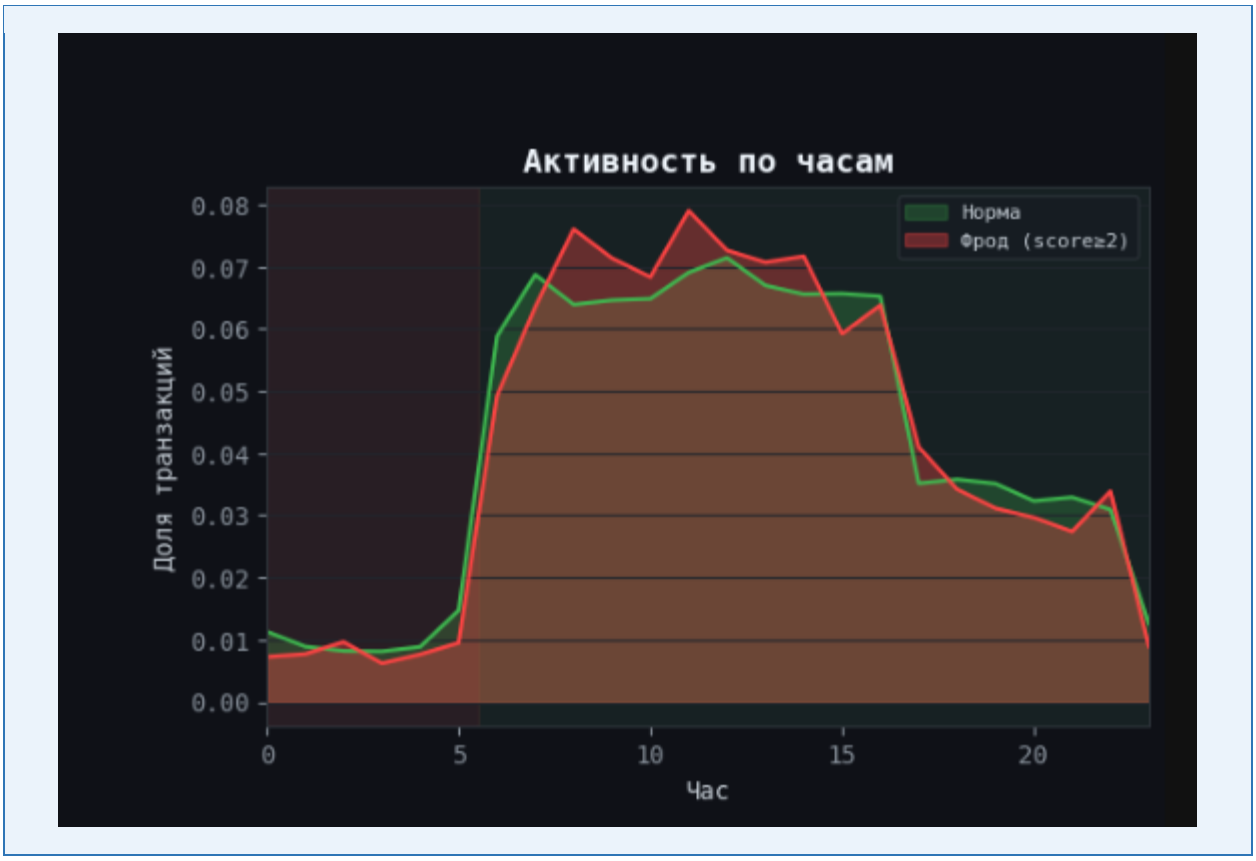

Что показывает график:

- Красная зона (фрод): заметный пик в ночные часы 0-5, особенно в 00:00-02:00
- Зеленая зона (норма): равномерный рост с утра, пик в 11-15, спад вечером
- Ночные часы (0-5) закрашены красным фоном — визуально выделена опасная зона

Вывод: фрод-клиенты статистически активнее ночью. Это подтверждает гипотезу flag_night — несанкционированное использование карты чаще происходит когда владелец спит.

3.3 Корреляция флагов (Heatmap)

Тепловая карта показывает насколько сильно связаны флаги между собой. Если два флага всегда срабатывают вместе — они скорее всего измеряют одно и то же, и один из них лишний.

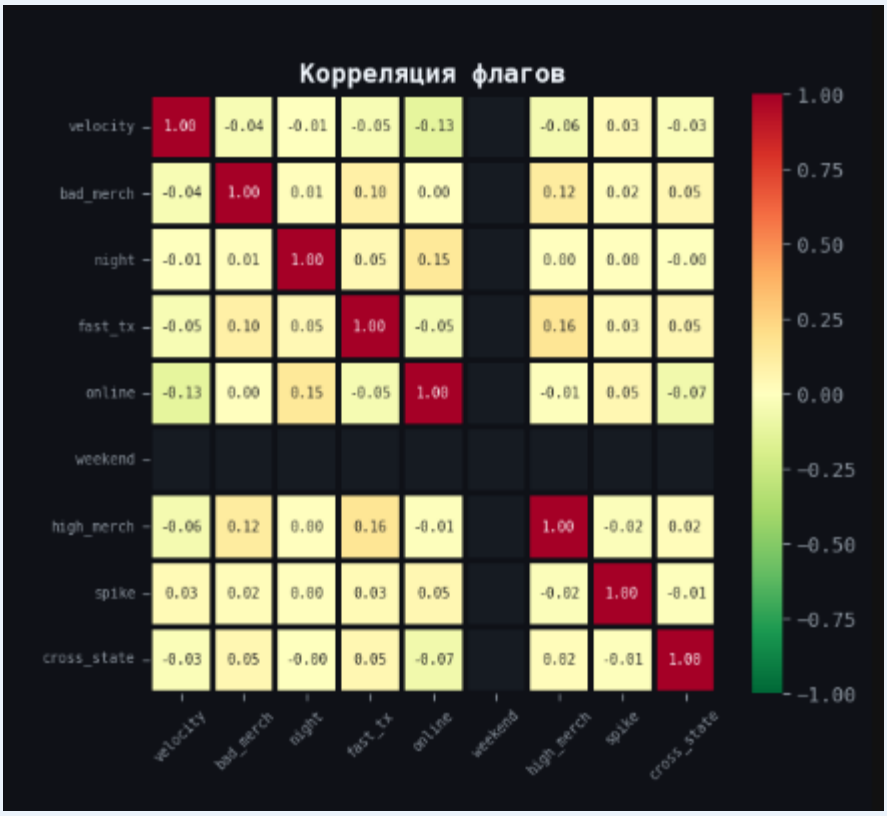

Что показывает график:

- Диагональ всегда 1.00 — каждый флаг коррелирует сам с собой
- Значения близкие к нулю — флаги независимы, каждый ловит свой паттерн
- Отрицательные значения — флаги взаимоисключающие

Вывод: низкая корреляция между флагами говорит о том что каждый из них улавливает уникальный паттерн фрода. Это хорошо — они дополняют друг друга, а не дублируются.

3.4 Топ подозрительных мерчантов

График 1 — Типы ошибок: Плохие vs Все мерчанты

Сгруппированный barh chart сравнивает три типа ошибок у подозрительных мерчантов (красные) против всех мерчантов (синие).

- Insufficient Balance (68%) — самый частый тип у плохих мерчантов. У всех мерчантов тоже высокий (69.2%) — этот тип встречается повсеместно
- Bad PIN (26.4%) — у плохих мерчантов в 1.5x выше чем у всех (17%). Клиенты вводят PIN неправильно — возможно карта скомпрометирована и данные подбираются
- Technical Glitch (11.7%) — у плохих мерчантов ниже чем у остальных (15.9%). Случайные сбои не связаны с фродом
-

График 2 — Распределение ошибок у подозрительных мерчантов (Donut)

Кольцевая диаграмма показывает только подозрительных мерчантов. Всего 412 ошибочных транзакций — в центре указано их количество.

- Insufficient Balance — 68% (большой красный сектор) — доминирует
- Bad PIN — 20.4% (желтый сектор) — каждая пятая ошибка, признак подбора PIN
- Technical Glitch — 11.7% (оранжевый) — случайные сбои, не фрод-паттерн

График 3 — Таблица топ-20 подозрительных мерчантов

Детальная таблица с ID мерчанта, процентом ошибок, количеством транзакций, средним чеком и штатом.

- Все топ-20 мерчантов имеют 100% ошибок — каждая транзакция завершилась с ошибкой
- Средний чек варьируется от $9 до $539 — большой разброс говорит о разных схемах фрода
- Большинство мерчантов имеют всего 1 транзакцию — одноразовые терминалы созданные специально для мошенничества
- Географически — TX, NY, CA, MI, FL дают большинство подозрительных мерчантов

Вывод: ключевой признак фрод-мерчанта — Bad PIN в сочетании с 100% ошибок. Это паттерн скиммера или фиктивного терминала где мошенник пытается подобрать PIN к скомпрометированной карте. Клиенты которые платили у таких мерчантов автоматически получают flag_bad_merch.

Горизонтальная гистограмма топ-20 мерчантов у которых самый высокий процент ошибочных транзакций.

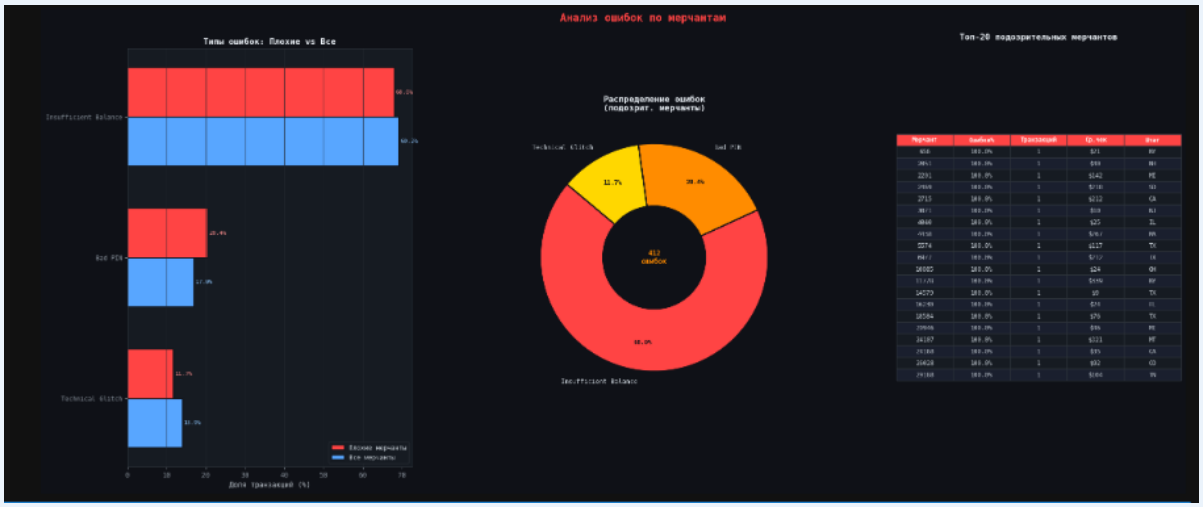

3.5 Ночные vs Дневные траты (Scatter plot)

Точечный график где каждая точка — один клиент. По оси X — его средний дневной чек, по оси Y — средний ночной чек. Цвет точки соответствует уровню риска клиента.

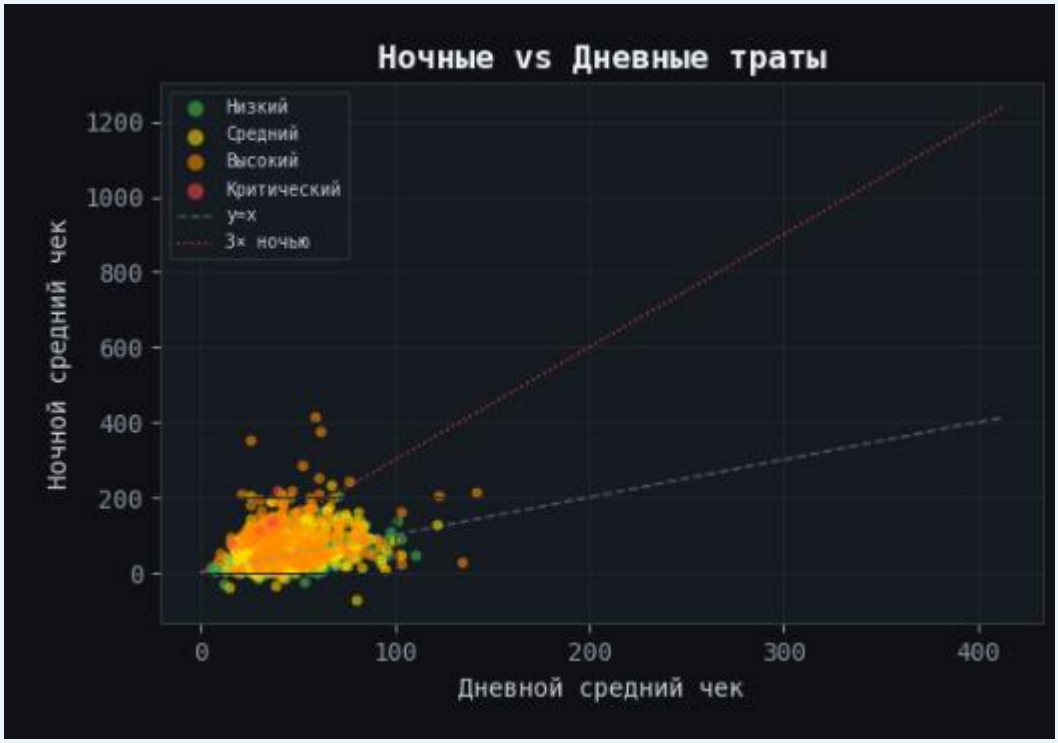

Что показывает график:

- Пунктирная линия y=x — все точки выше неё тратят ночью больше чем днём
- Красная пунктирная линия y=3x — граница флага flag_night (в 3 раза выше)
- Красные и оранжевые точки (высокий риск) сконцентрированы выше линии 3x
- Зелёные точки (низкий риск) плотно у начала координат — нормальное поведение

Вывод: визуально видно что клиенты с высоким риском действительно тратят ночью аномально много. График подтверждает правило флага.

3.6 Состав флагов по уровню риска (Stacked Bar)

Составная столбчатая диаграмма показывает из каких именно флагов состоит каждый уровень риск-скора. Каждый цвет в столбике — один флаг.

Что показывает график:

Вывод: большинство подозрительных клиентов имеют 3 флага. Клиентов с 5+ флагами мало, но они требуют приоритетного внимания.

3.7 Машинное обучение — сравнение 5 моделей

После построения флагов я обучил 5 ML моделей на агрегированных признаках клиентов. Целевая переменная — is_fraud (risk_score >= 3). Данные были сбалансированы через SMOTE так как фрода всего 3.2%.

Использованные модели:

- Random Forest — ансамбль из 200 деревьев решений
- XGBoost — градиентный бустинг, хорошо работает с дисбалансом
- LightGBM — быстрая версия бустинга от Microsoft
- Gradient Boosting — классический бустинг из sklearn
- Logistic Regression — базовая линейная модель для сравнения

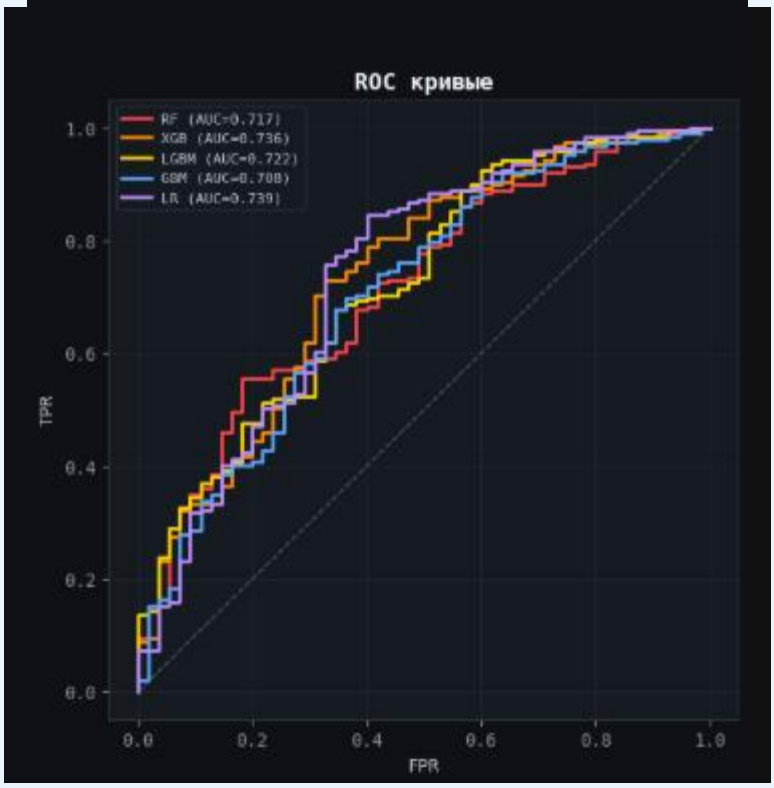

Результаты сравнения моделей:

Модель	AUC	Recall (фрод)	F1
Logistic Regression	0.739	0.75	0.33
XGBoost	0.736	0.62	0.38
LightGBM	0.722	0.60	0.34
Gradient Boosting	0.708	0.58	0.32
Random Forest	0.717	0.50	0.28

Лучшая модель по AUC — Logistic Regression (0.739). Recall 0.75 означает что модель находит 3 из 4 реальных фродеров. Низкий Precision (0.21) — ожидаемо при дисбалансе 3.2%, но в задаче фрод-детекции пропущенный фрод дороже ложной тревоги.

3.8 Anomaly Detection — Isolation Forest

Дополнительно я применил Isolation Forest — это алгоритм обнаружения аномалий без размеченных данных. Он сам ищет транзакции которые сильно отличаются от остальных, без каких-либо правил.

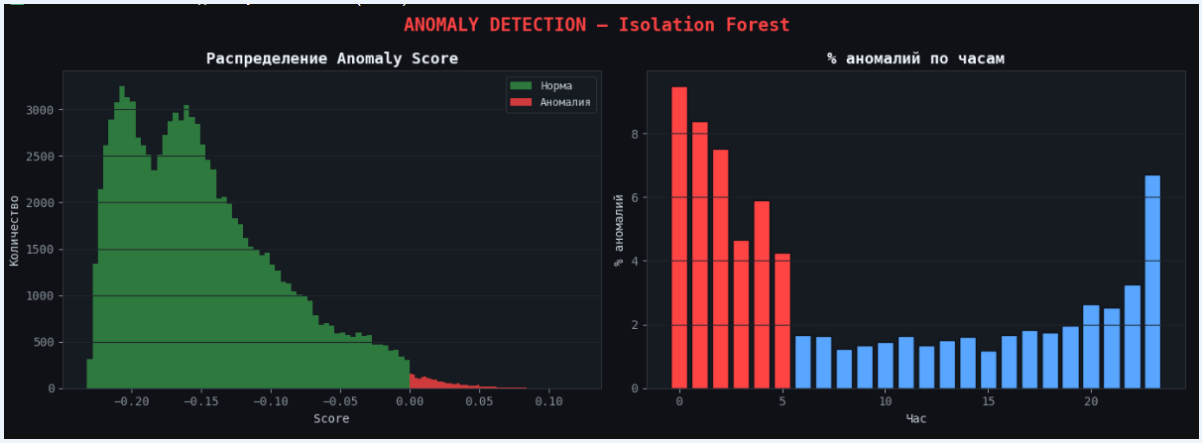

Ключевые находки:

- Найдено 2,000 аномальных транзакций (2%) из 100,000 проверенных
- Средняя сумма аномалий: $151 против $40 у нормальных — в 3.7 раза выше
- 55% аномалий — онлайн транзакции (vs 11% у нормальных)
- 56% аномалий содержат ошибку мерчанта (vs 1% у нормальных)
- Пик аномалий в ночные часы 0-5 — модель сама подтвердила наш flag_night

Вывод: алгоритм без каких-либо правил нашел те же паттерны что и наши ручные флаги. Это говорит о том что флаги были подобраны правильно.

4. Итоги и выводы

По итогам анализа удалось построить комплексную систему выявления фрода на транзакционных данных. Работа прошла в два этапа: SQL для проверки гипотез и Python для полноценной системы скоринга с ML.

4.1 Итоговая сводка

Что сделано	Результат
SQL анализ	4 гипотезы, выявлены основные паттерны фрода
Флаги фрода	9 флагов на основе правил, покрывают разные сценарии
Risk Scoring	756 клиентов с флагами, 39 в зоне высокого риска
ML модели	5 моделей, лучший AUC 0.739 (Logistic Regression)
Anomaly Detection	2,000 аномальных транзакций найдено без разметки
Итоговый отчет	Каждый клиент получил статус от Чистый до Подтвержденный фрод

4.2 Финальные статусы клиентов

В конце каждый из 1,219 клиентов получил итоговый статус на основе комбинации флагов и ML предсказания:

Статус	Условие
Чистый	Нет флагов, ML не нашел
Подозрительный	1-2 флага срабатывает
Высокий риск	3-4 флага
ML-фрод	Только ML модель нашла
Критический	5+ флагов
Подтвержденный фрод	И флаги (3+) И ML согласны

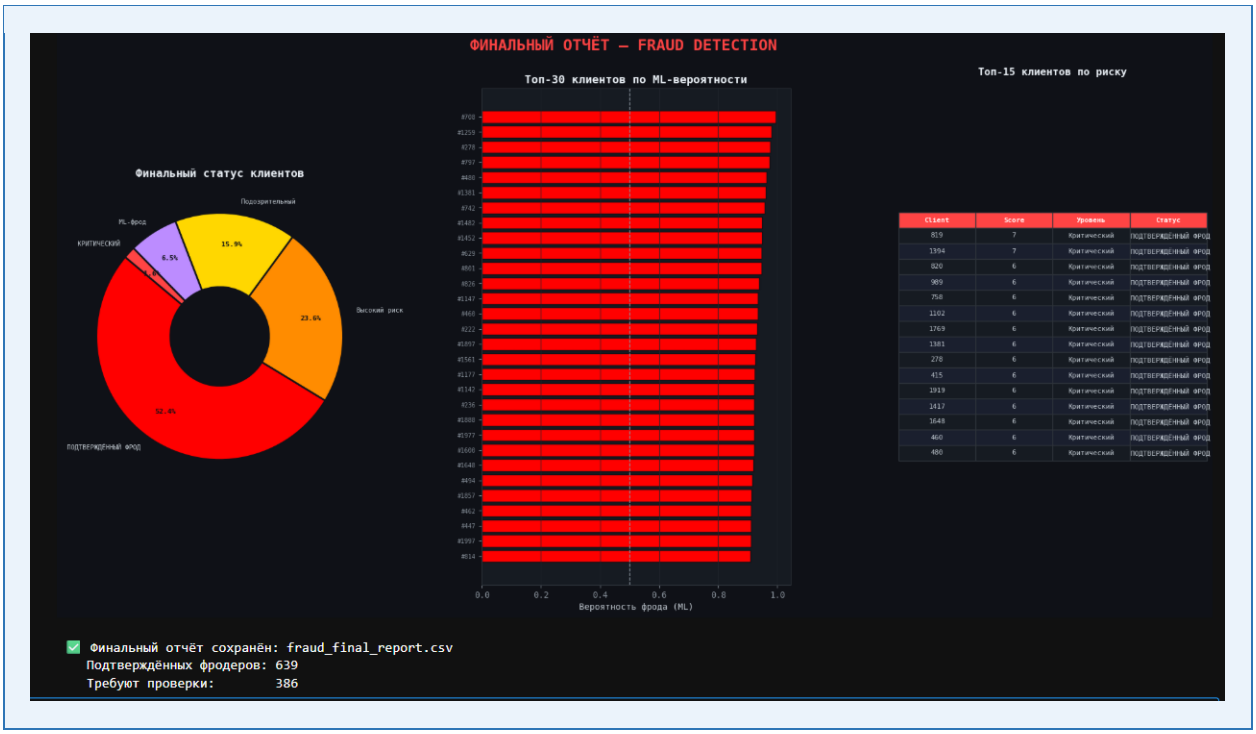

4.3 Рекомендации

- Усилить мониторинг транзакций в ночные часы (00:00-05:00)
- Провести расследование мерчантов в CA с 100% ошибок
- Внедрить автоматический velocity check — блокировка при >10 транзакций/час
- Приоритизировать клиентов с risk_score >= 3 для ручной проверки
- Усилить верификацию онлайн транзакций выше $100
- Собрать реальную разметку фрода чтобы улучшить качество ML моделей

4.4 Что можно улучшить

Главное ограничение проекта — отсутствие реальных меток фрода. Все флаги основаны на экспертных гипотезах, а ML модели обучаются на них же. Это приводит к data leakage когда модель просто запоминает правила.

Для улучшения качества потребуется: разметка реальных случаев мошенничества от команды безопасности, более глубокие поведенческие фичи (графы транзакций, временные ряды), и возможно нейросетевые подходы для sequence modeling.